ClickHouse在B站海量数据场景的落地实践

胡甫旺
哔哩哔哩OLAP平台

目录

- ClickHouse在B站
- 内核
- 日志
- 用户行为数据分析
- Future Work
- Q&A

ClickHouse在B站

B站ClickHouse应用概况

- 近400个节点，30个集群
- 日均1.5+万亿条数据摄入
- 日均800+万次Select请求
- 应用场景包括（不限于）：
  - 日志&Trace分析
  - 用户行为分析（包括事件分析，漏斗分析，路径分析等）
  - 圈人定投
  - 广告DMP（包括统计分析，人群预估）
  - 电商交易分析
  - OGV内容分析
  - APM (Application Performance Management)

基于ClickHouse的交互式OLAP技术架构

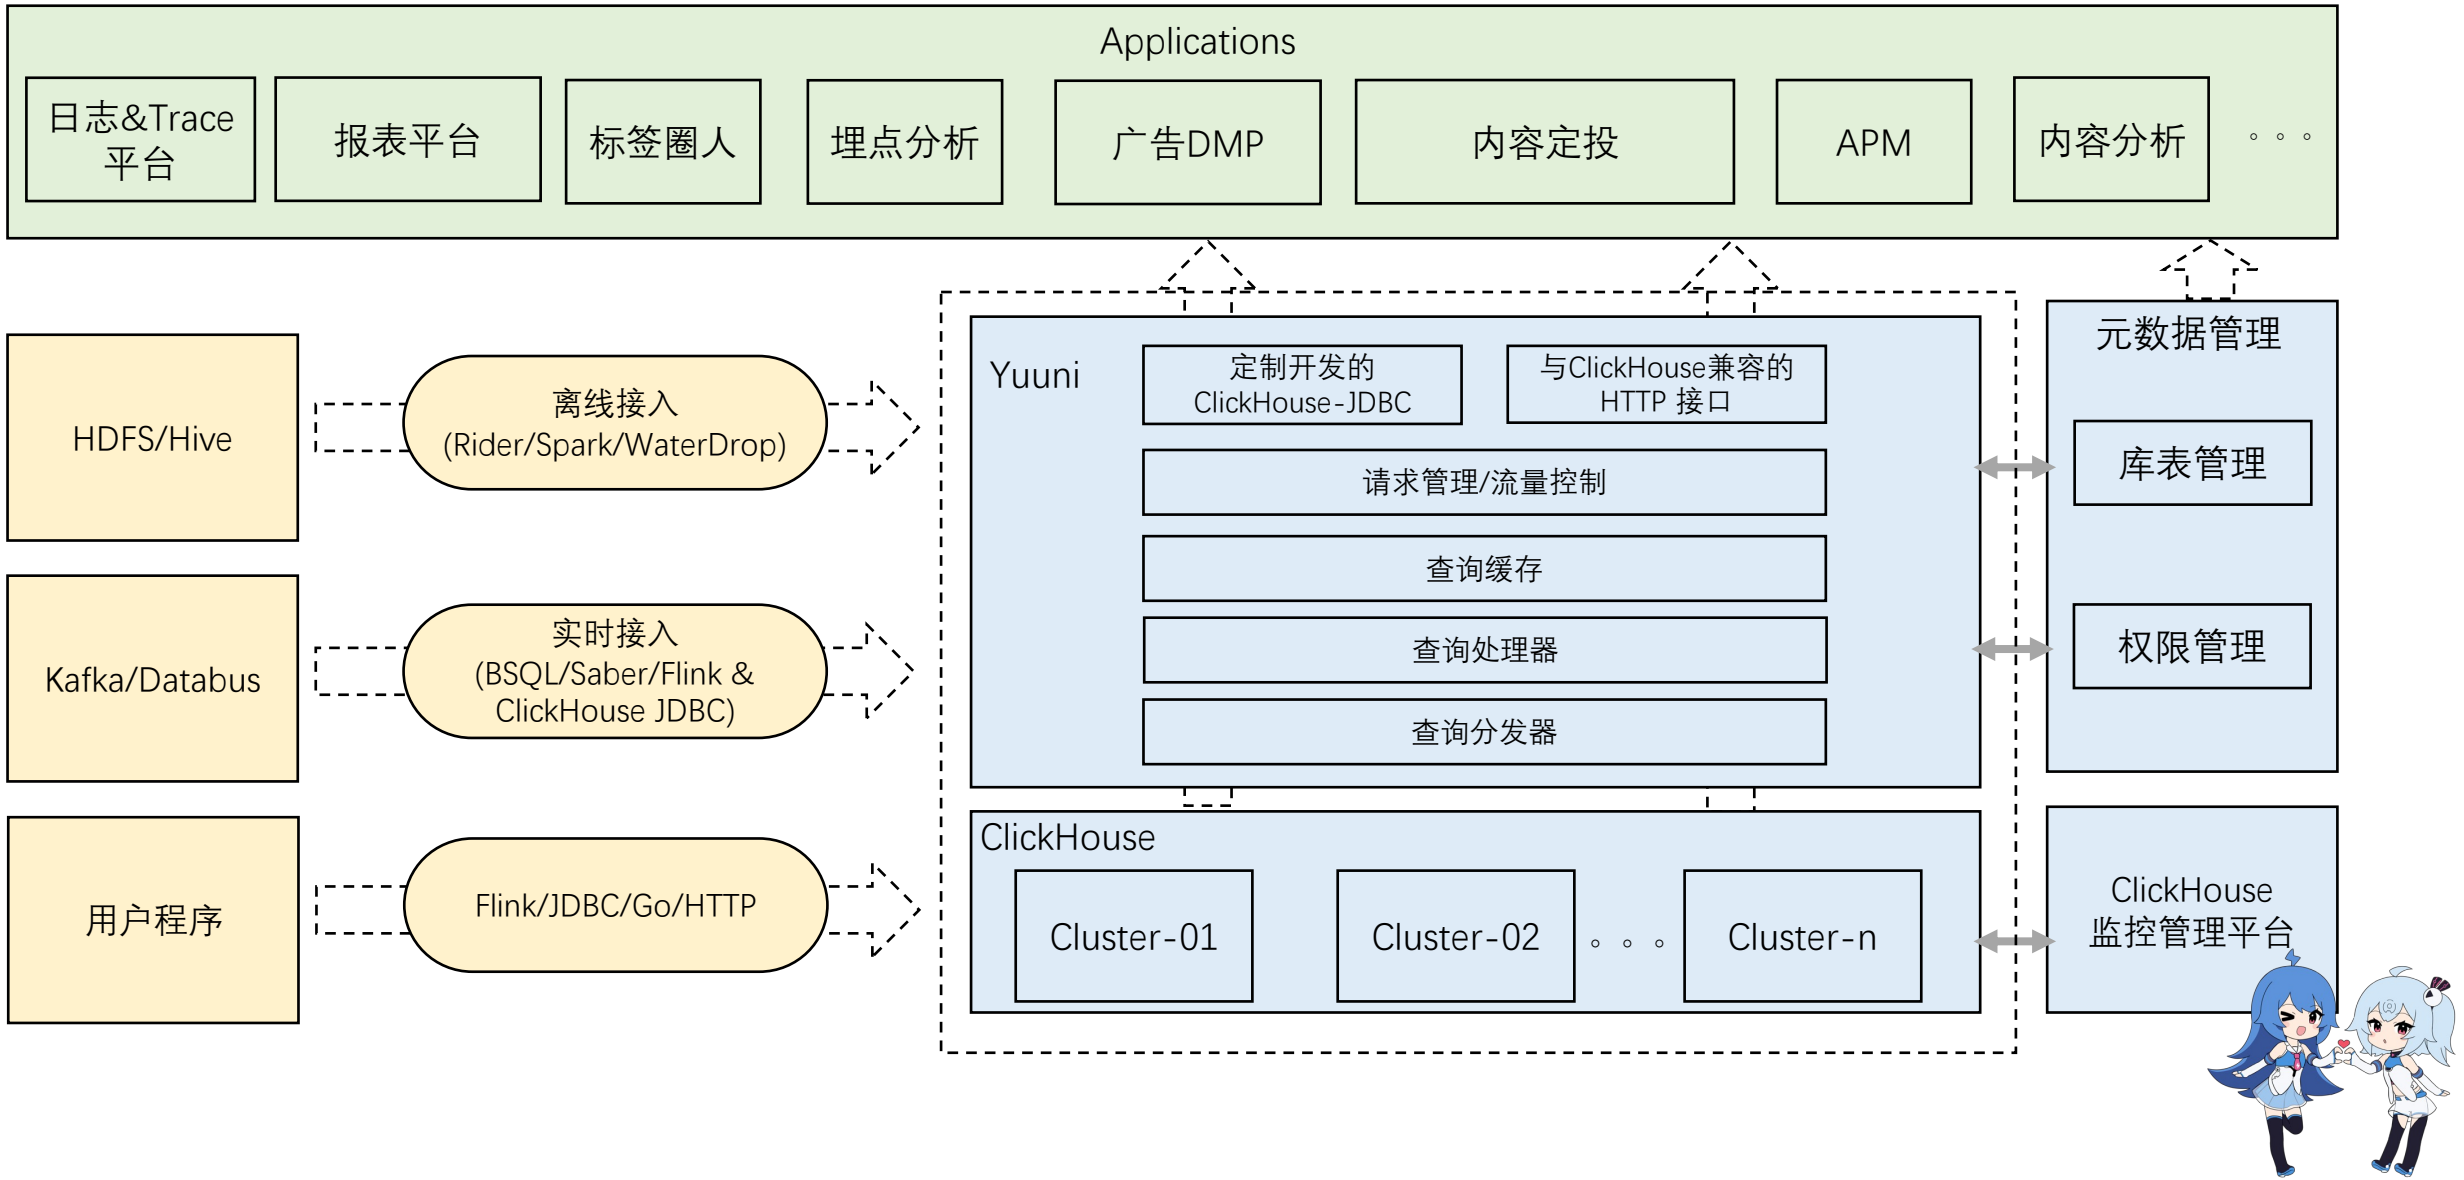

ClickHouse as Service

- Berserker数据源管理：
  - 建表
  - 修改表元数据
  - 表元数据管理
- Yuuni：
  - 屏蔽集群信息
  - 原生JDBC，HTTP接口
  - 读写分离
  - 动态查询缓存
  - 流量控制
- 监控管理平台：
  - 统计大盘
  - 回归测试
  - 接入评估
  - 数据迁移
  - 数据重平衡
- 交互式分析查询：Superset提供即时查询能力
- 离线写入服务 （Rider）
- 实时写入服务 （BSQL/Saber）

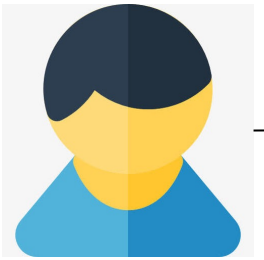

用户

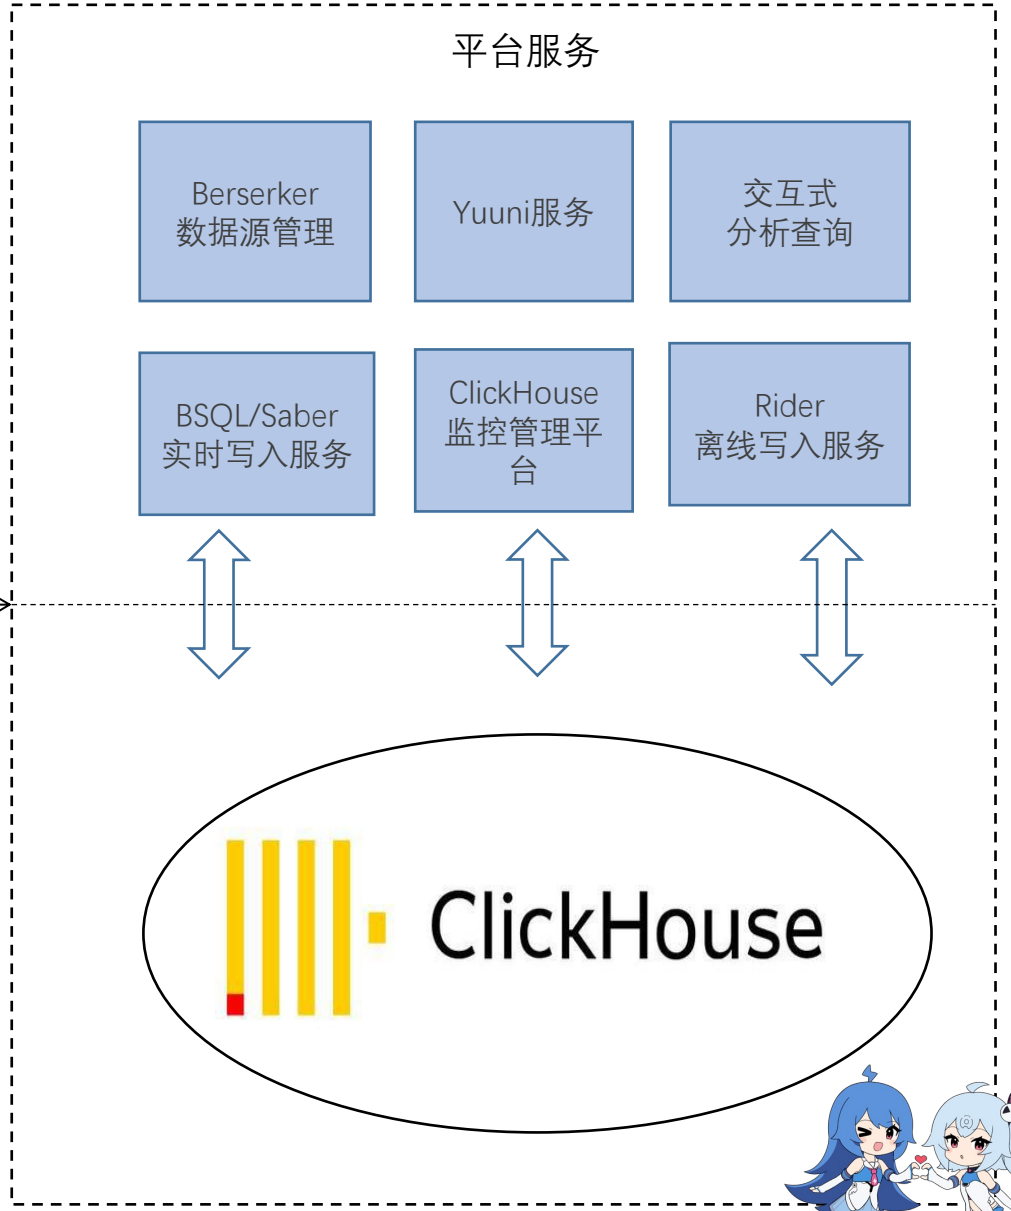

内核

Map隐式列

- 原生Map使用Array of Tuple实现
- 原生Map查询时需读取大量无效数据

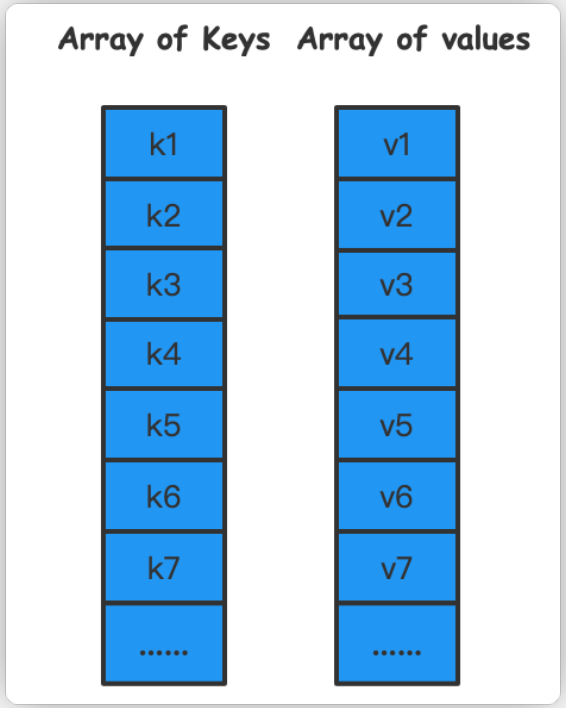

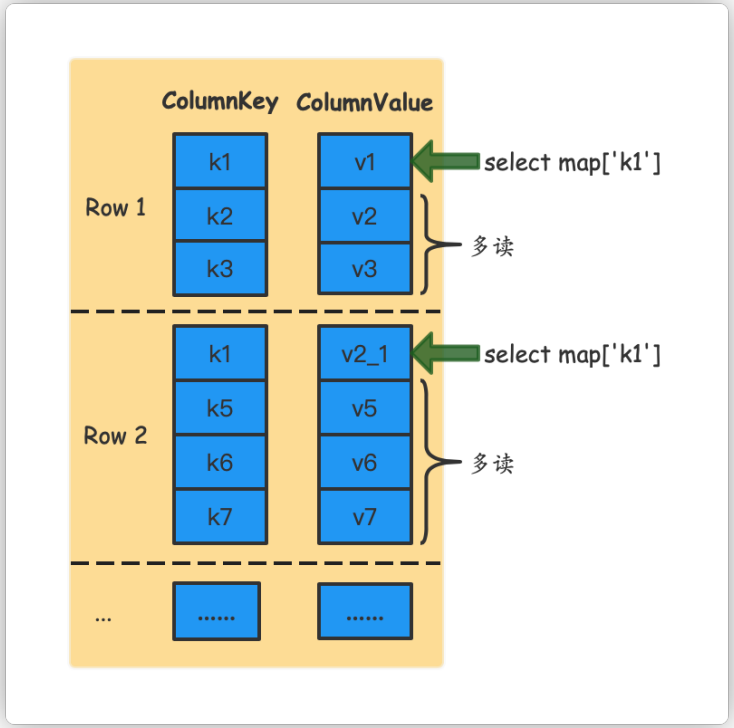

Map隐式列

- Map隐式列将每个Key存储为独立列
- Map隐式列查询时只读取需要的隐式列

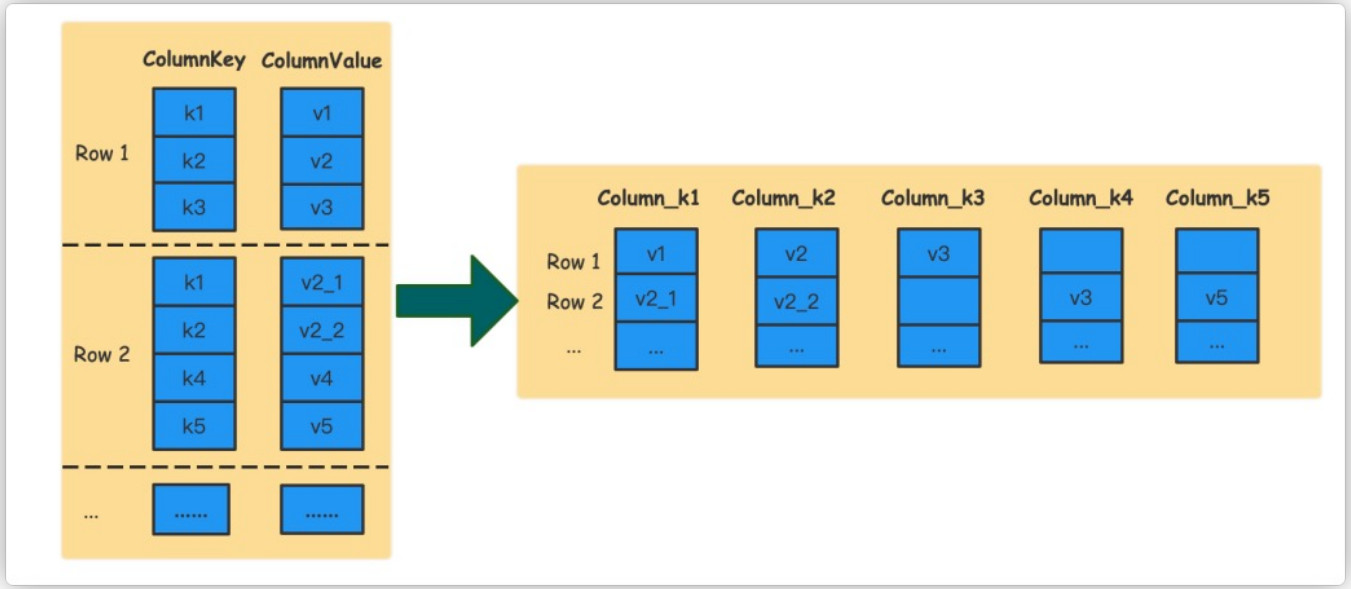


```
CREATE TABLE mapv2_table
(
    `id` UInt32,
    `map` MapV2(String, String)
)
ENGINE = MergeTree
ORDER BY id

Query id: f89ece2e-fd4a-421b-8f24-121e367c16f2

Ok.

0 rows in set. Elapsed: 0.003 sec.
```

Bulkload

- 原生写入方式消耗ClickHouse Server资源，影响查询性能
- 实时写入任务长期占用资源，故障恢复的时间和运维成本较高
- 基于中间存储的Bulkload方案降低ClickHouse Server压力

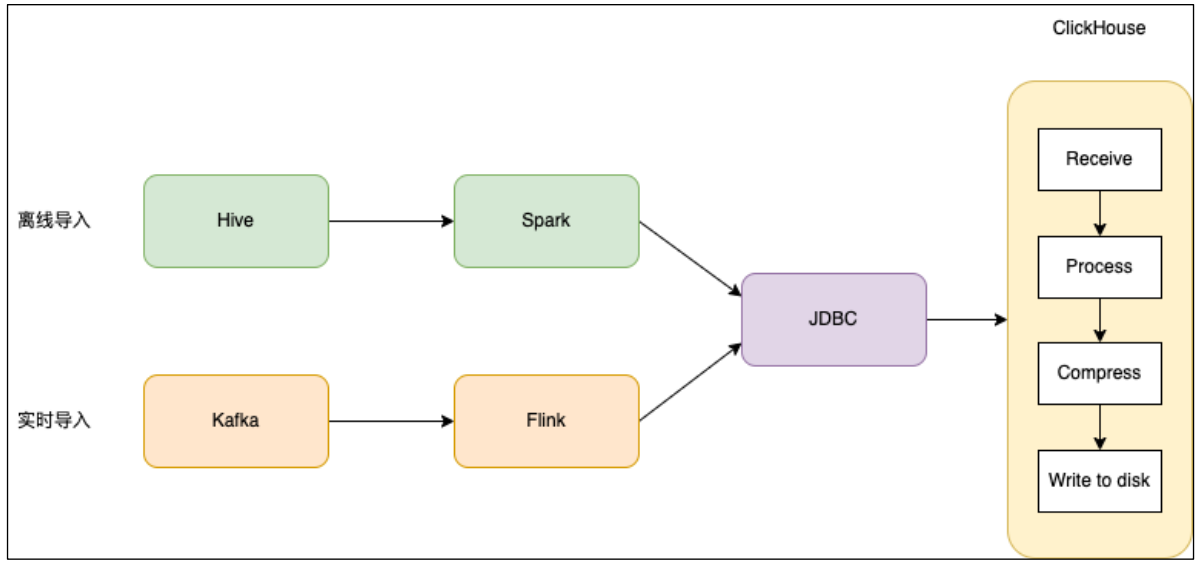

Bulkload

- 基于中间存储的Bulkload可以降低ClickHouse Server压力
- 基于中间存储的Bulkload受HDFS和网络稳定性影响，且传输成本较高
- 直达ClickHouse的Bulkload稳定性，性能都更佳

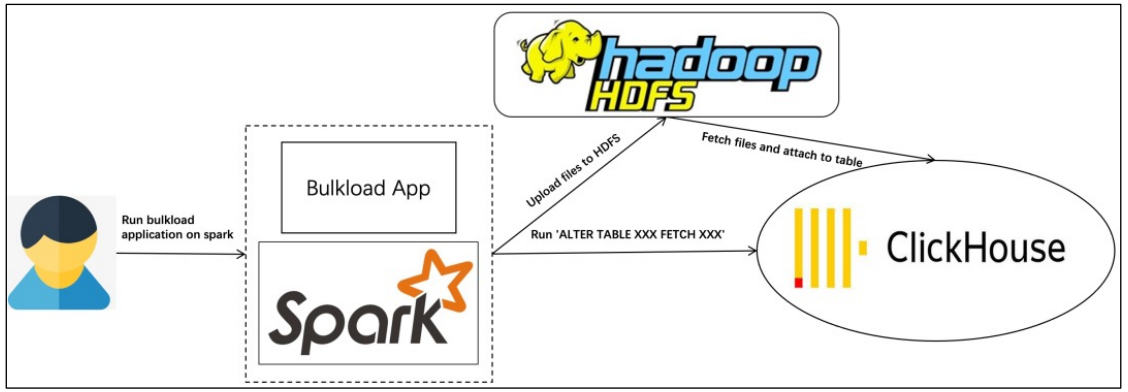

Unique Engine

- 目标：支持UpSert，Delete操作，提升查询性能
- 设计：delete on insert

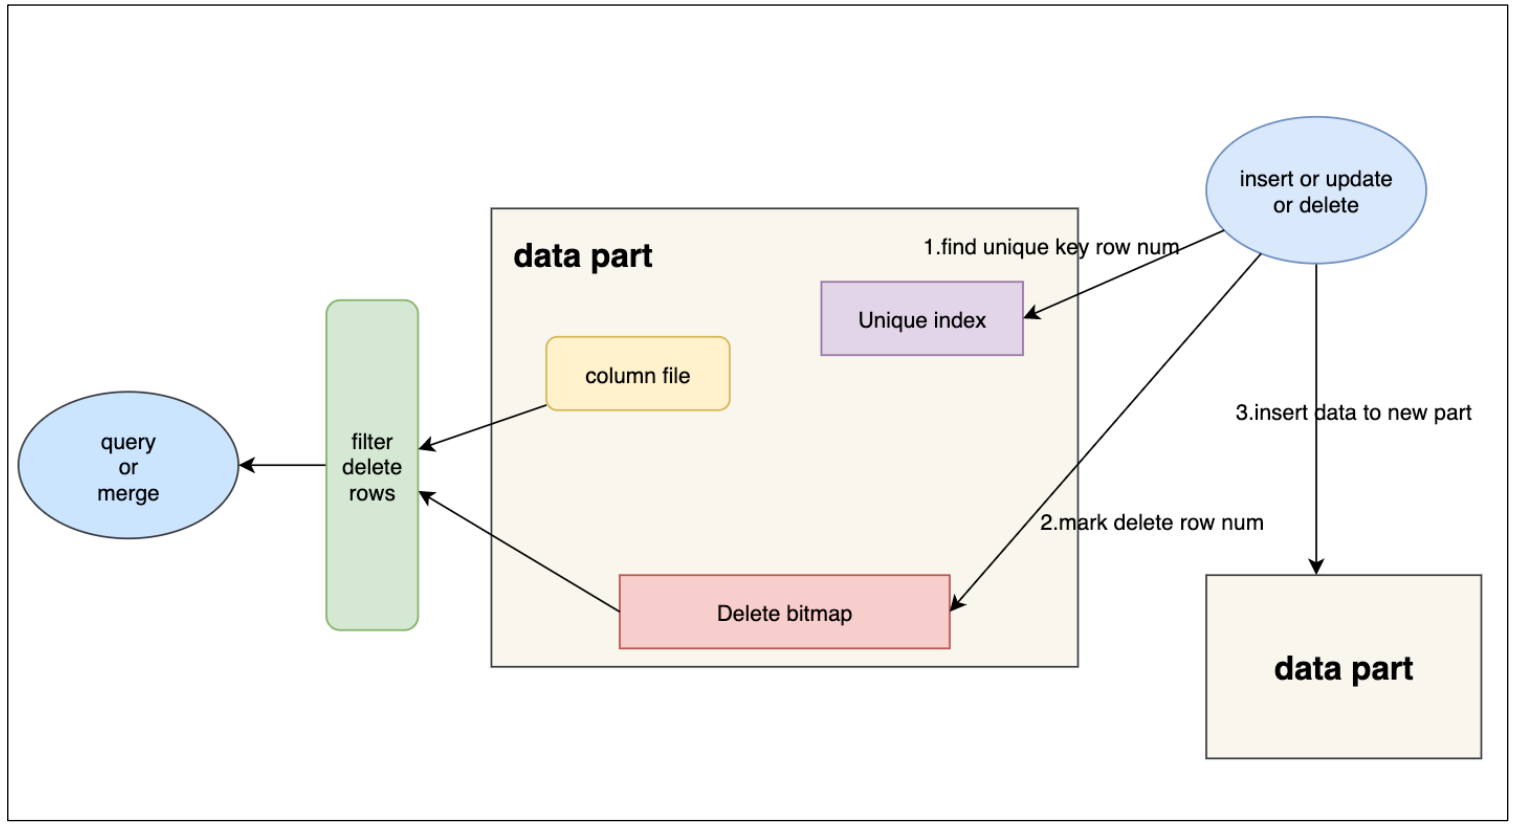

Unique Engine

- write-write冲突依靠table level lock控制
- write-merge冲突：

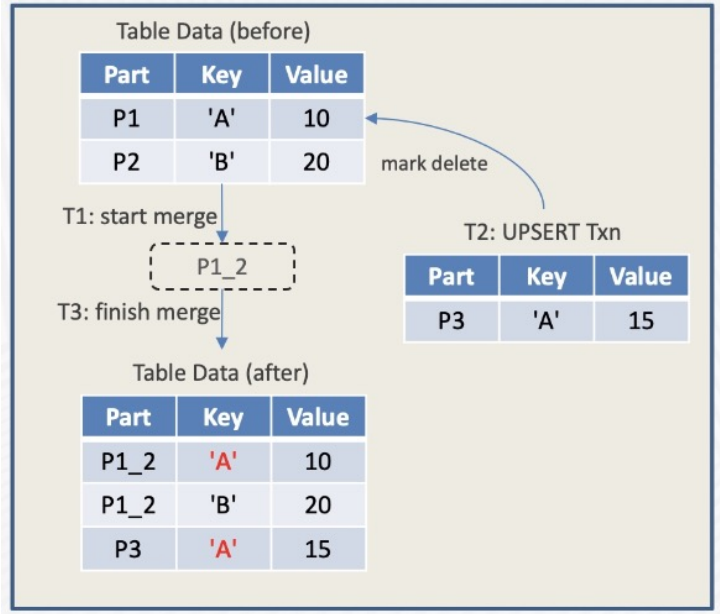

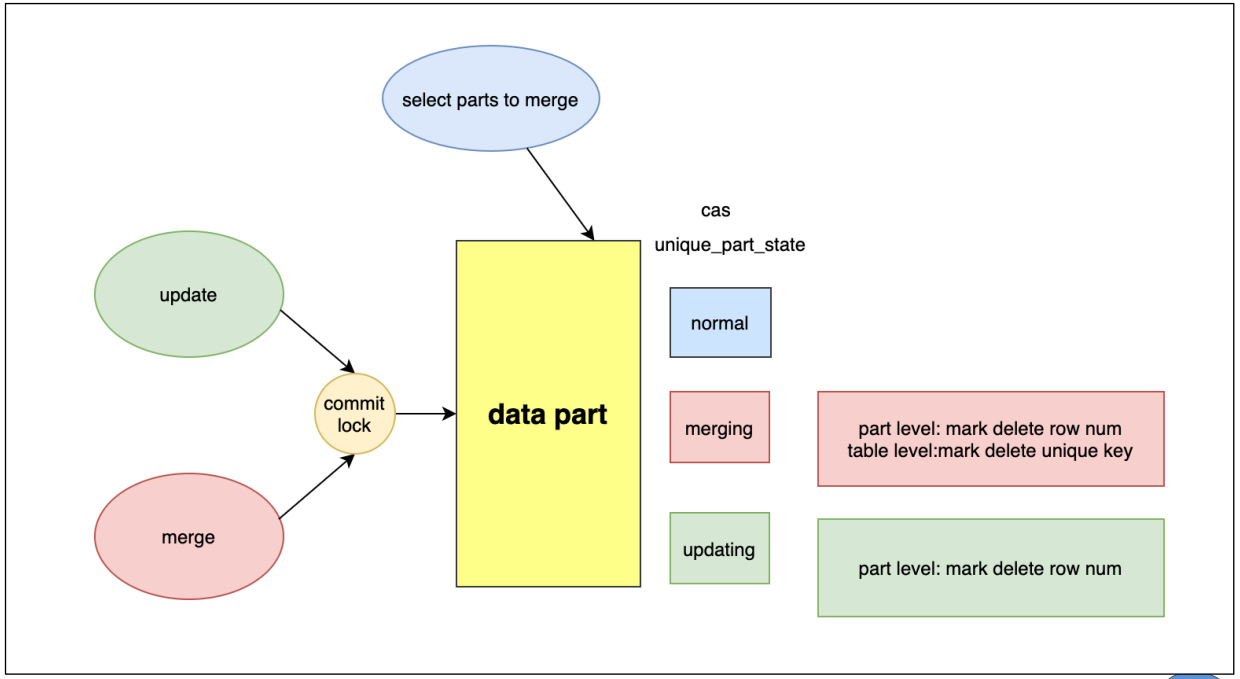

Unique Engine

- 常驻内存模式对内存消耗很大
- 非常驻内存模式index load过程慢
- 多并发加载优化索引加载速度：

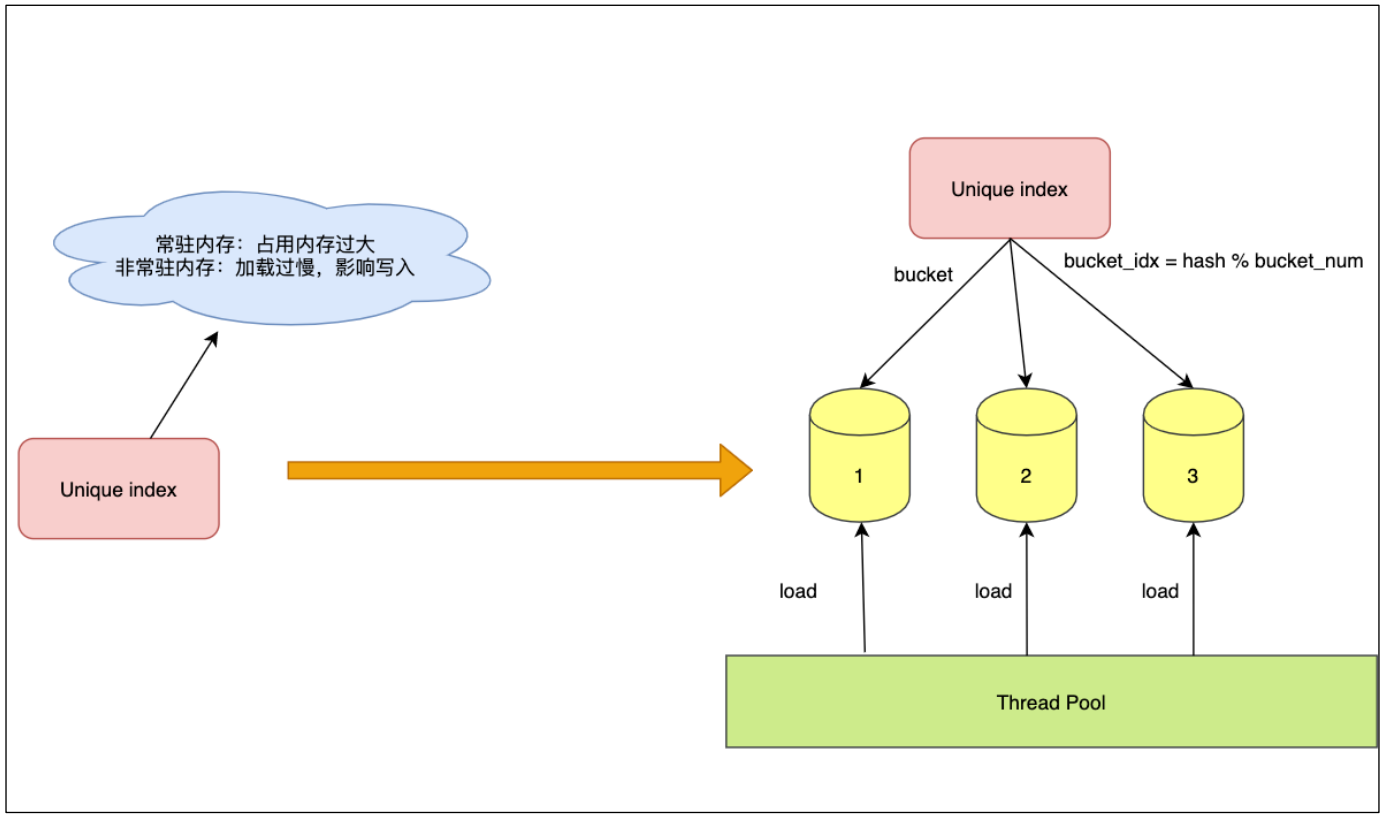

日志

日志

- Elastic To ClickHouse迁移，降本增效
- OTEL标准化日志采集
- 统一scheme支持

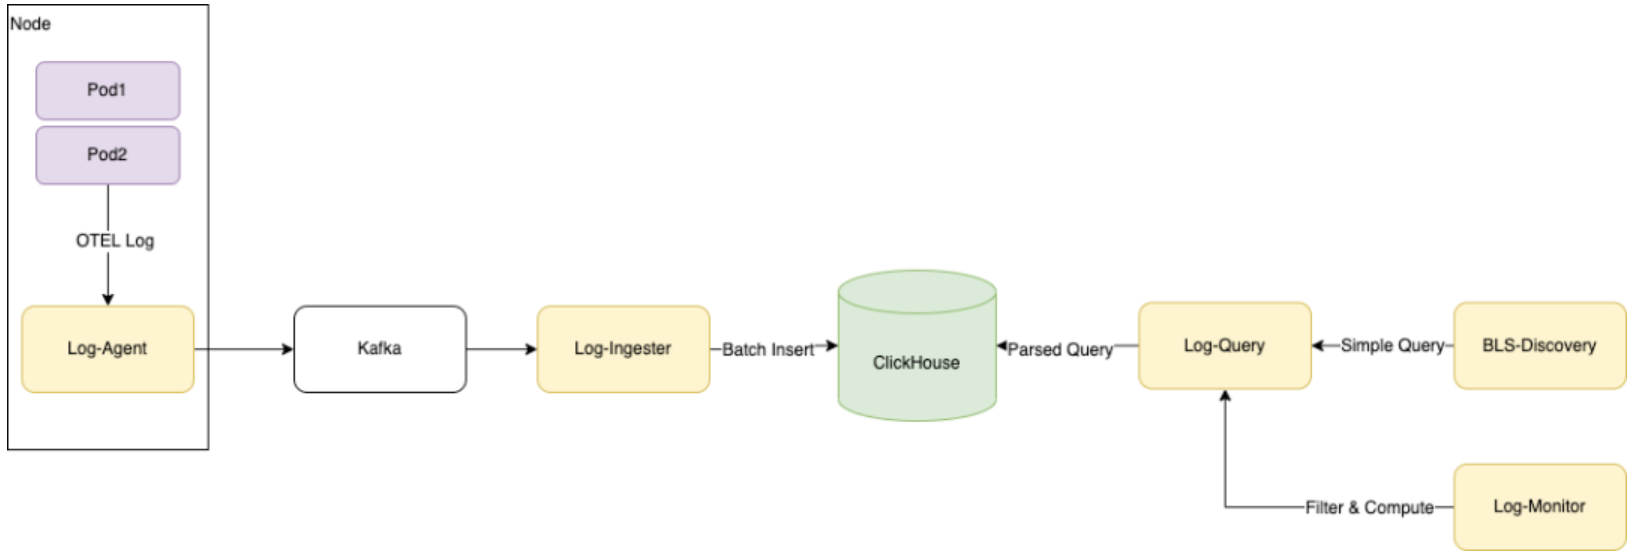

日志

- ClickHouse较ES写入吞吐量提升近10倍
- ClickHouse存储成本为ES的1/3

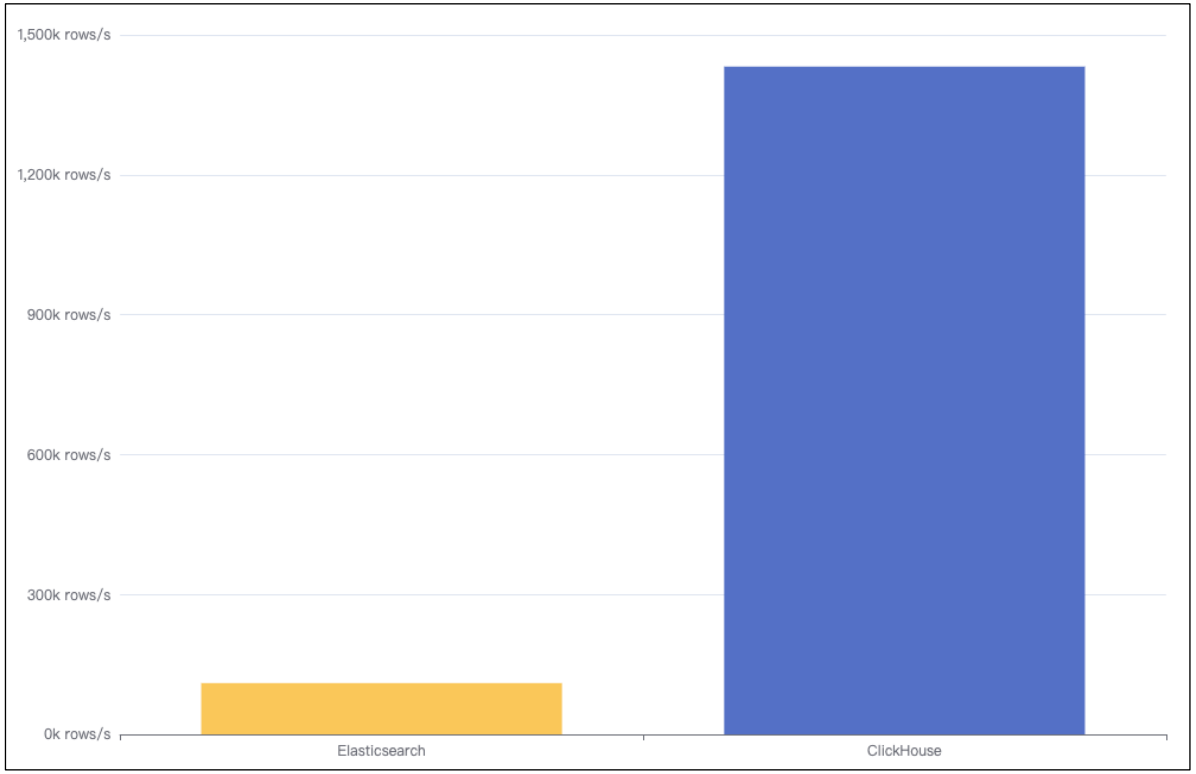

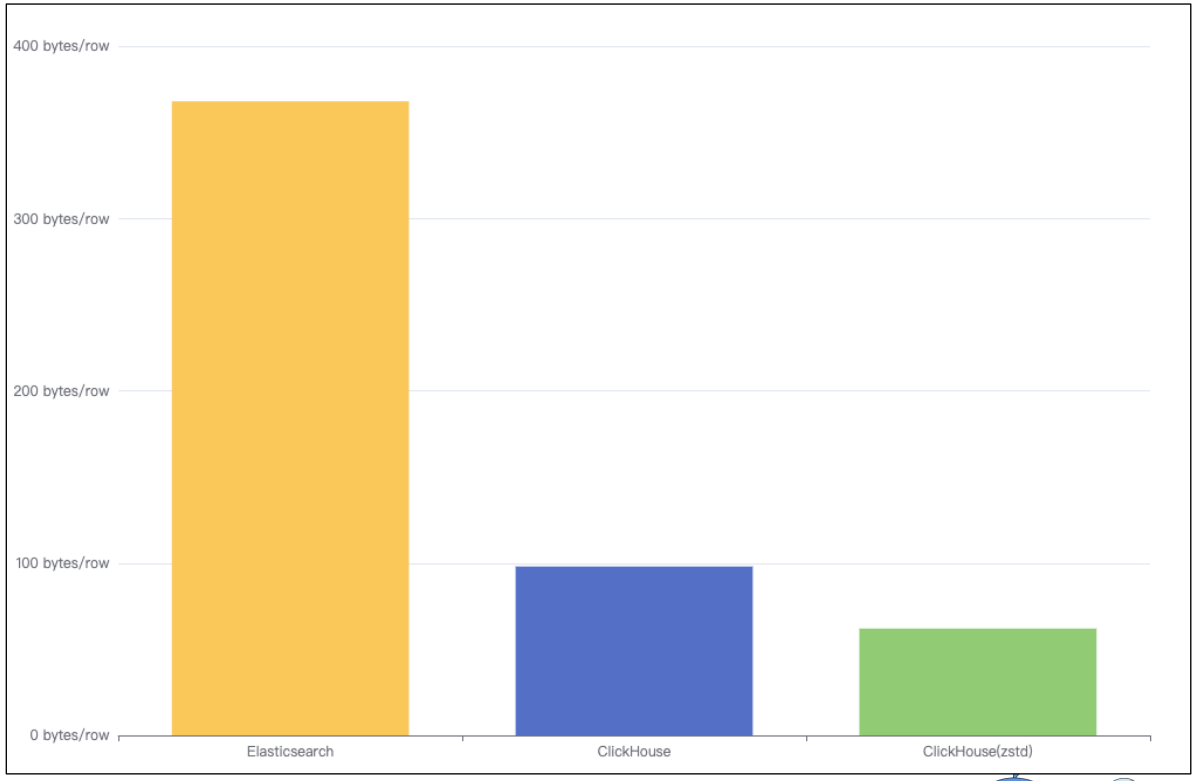

日志

- ClickHouse中采用分表，统一schema的设计
- 日志查询采用类似ES语法，降低用户迁移成本

```
Create Table <log_app_name> ON CLUSTER ...
{
    _timestamp      Datetime64(3),
    `log.level`     String CODC(ZSTD(1)),
    `log.msg`       String CODC(ZSTD(1)),
    `log.trace_id`  String CODC(ZSTD(1)),
    ...
    string_map  MapV2(String, Nullable (String))
        CODEC(ZSTD(1))
    number_map  MapV2(String, Nullable (Float64))
        CODEC(ZSTD(1))
    bool_map  MapV2(String, Nullable (UInt8))
}
ENGIN = ReplicatedMergeTree(...)
PARTITION BY toYYYYMMDD(_timestamp)
ORDER BY timestamp
TTL toDateTime(timestamp) + toIntervalDay(...),
  toDateTime(timestamp) + toIntervalDay(...) TO VOLUME 'cold_volume'
```

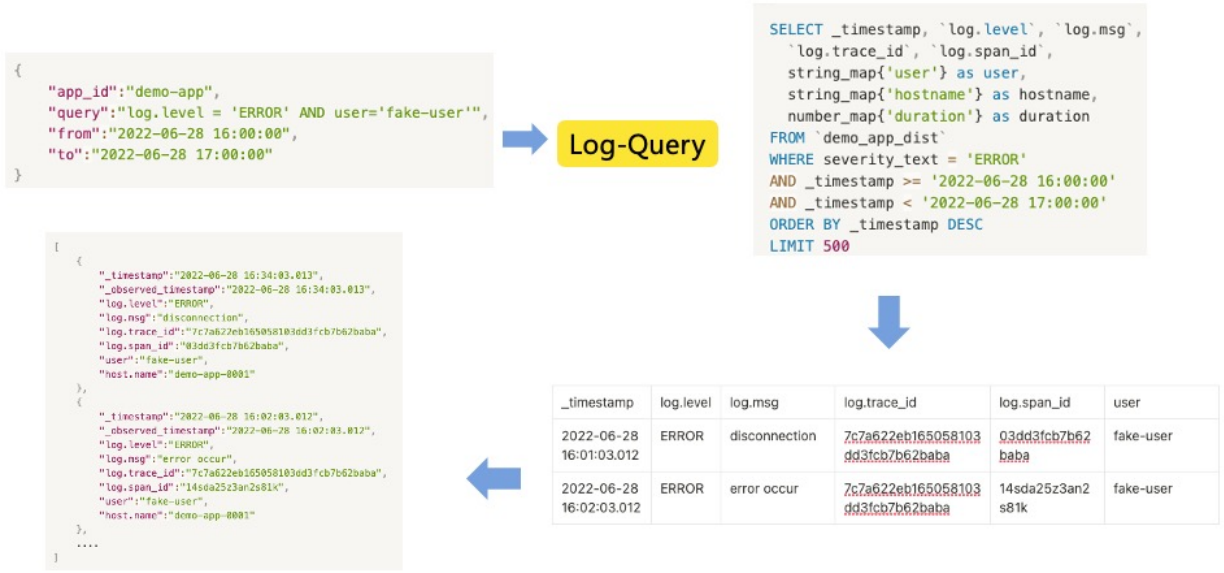

用户行为数据分析

概述

- 基于ClickHouse构建B站用户行为数据分析产品：北极星
- 行为数据分析平台主要以下功能模块：

事件分析

- 海量埋点事件数据，日增数据千亿级。
- 用户行为事件的多维度分析场景。
- 事件包含公共属性和私有属性，均可作过滤和聚合维度。
- 不同事件有不同的私有属性字段。
- 动态选择的过滤维度和聚合维度。
- 交互式分析延迟要求 (5秒内)。

路径分析

- 选定中心事件。
- 按时间窗口确定上下游事件。
- 离线Spark与计算出事件路径及相关用户id的RBM。
- 离线计算结果导入ClickHouse做交互式路径分析。

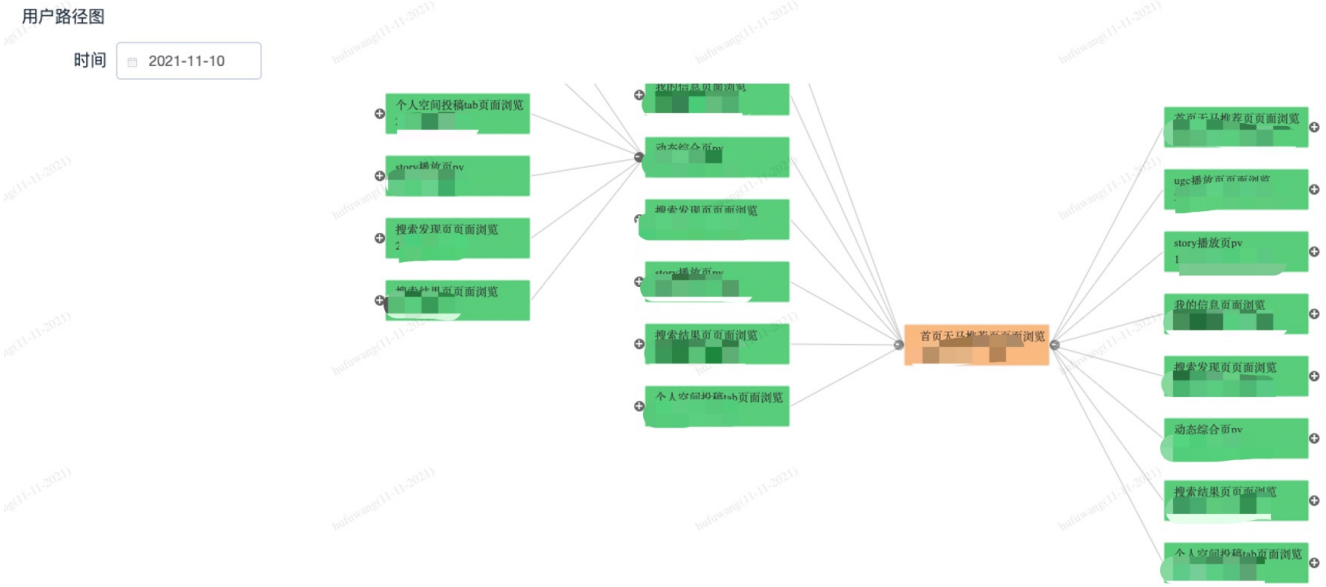

漏斗分析

- 预定义事件漏斗
- 支持各个事件单独设置过滤条件
- 查询时间跨度最大一个月
- 数据按user id做Sharding，查询下推

```
select level, count(distinct buvid)
from (
    SELECT
    buvid,
    windowFunnel(3600)(time_iso, event_id = 1, event_id = 2, event_id = 3 , event_id = 4) AS level
    from event_analysis_table_dst
    where log_date=  '20201201'  and event_id in (1, 2, 3, 4)
    GROUP BY buvid
    settings distributed_group_by_no_merge=1
) group by level
```

```
select level, sum(cnt) as cnt
from cluster(  'cluster_name',
view(
  select level, count(distinct buvid) as cnt
   from (
  SELECT
  buvid,
  windowFunnel(3600)(time_iso, event_id = 1, event_id = 2, event_id = 3, event_id =4) AS level
  from event_analysis_table_local
  where log_date = 20201201'  and event_id in (1, 2, 3, 4)
  GROUP BY buvid
) group by level)
) group by level
```

Future Work

Future Work

- ClickHouse集群容器化，提升物理集群资源使用率
- ClickHouse倒排索引调研与改造，提升日志检索性能
- 丰富ClickHouse编码类型，拓展zorder应用场景，提升圈选计算性能
- ClickHouse存算分离探索，降低集群扩容成本

Q&A