



刘兆坤

vivo互联网

- 2016年从事大数据工作,对大数据计算引擎源码有深入研究,参与开源贡献
- 2019年加入vivo,从事内容分发、线上/线下营销业务的数仓建模、数据应用
- 2020年开始负责ABTest的数据能力建设



目录

CONTENTS

- 1、ABTest简介
- 2、ABTest计算架构演进
- 3、ClickHouse应用实践



一、ABTest简介



什么是ABTest、常见的统计陷阱、vivo ABTest的规模





APP通知弹窗案例-哪个方案的同意率更高?







目标:通过实验,**验证高同意 率组件**,持续提升弹窗同意率

- ,降低弹窗对app访问的影响
- ,提升app活跃

日均同意率:

用数据做客观评价

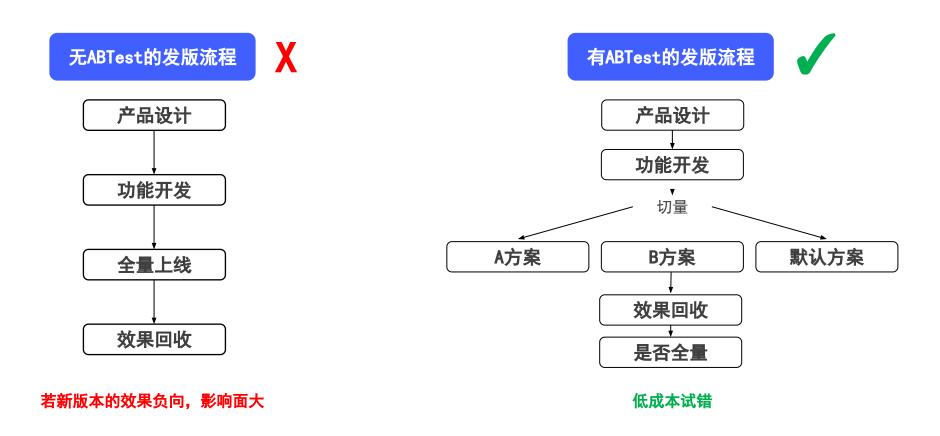
- 实验组A相对于对照组约提升3%
- 实验组B相对于对照组下降约10%

对照组 实验组A 实验组B





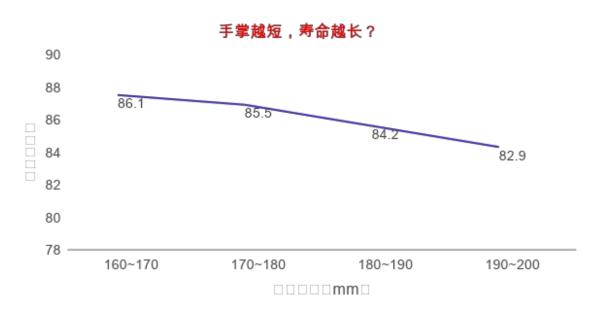
通过统计学方法,对比只有一个变量不同的同一产品的两个或多个不同版本的表现来研究该变量的作用以及影响。

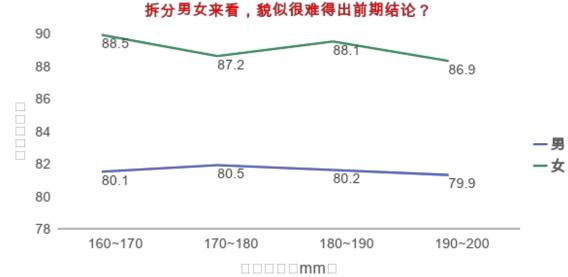






统计学中的经典案例-手掌长度与寿命长短存在关联吗?



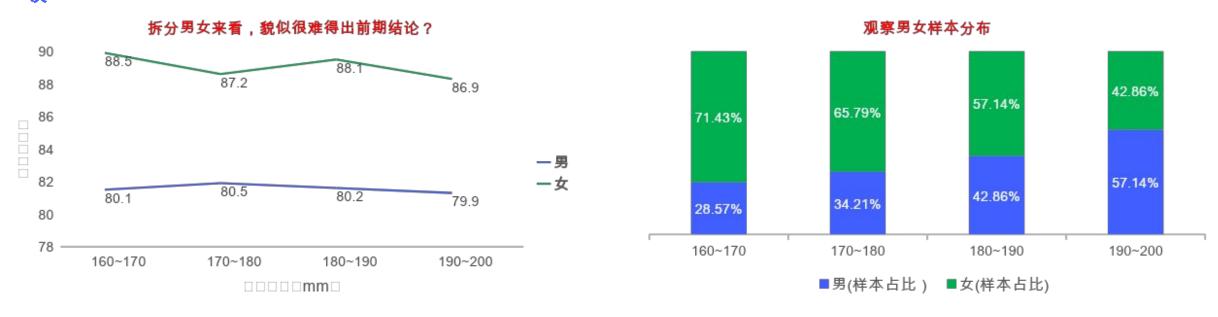




数据不会骗人? 所见即所得?

统计学中的经典案例-手掌长度与寿命长短存在关联吗?

初始结论得出的根本原因是样本比例差异,且女性比男性更长寿 , 女性比男性手更小。因此手掌长度与寿命并无直接关系, 结论错误



常见的统计陷阱





统计陷阱是数据分析过程中容易发生的偏差 和误解,需要谨慎对待并采取多方面的对策 来消除其影响。





规避实验效果统计陷阱,用合理的置信结果衡量实验效果,从而降低试错成本,提升决策效率!



平台概况







二、ABTest计算架构演进



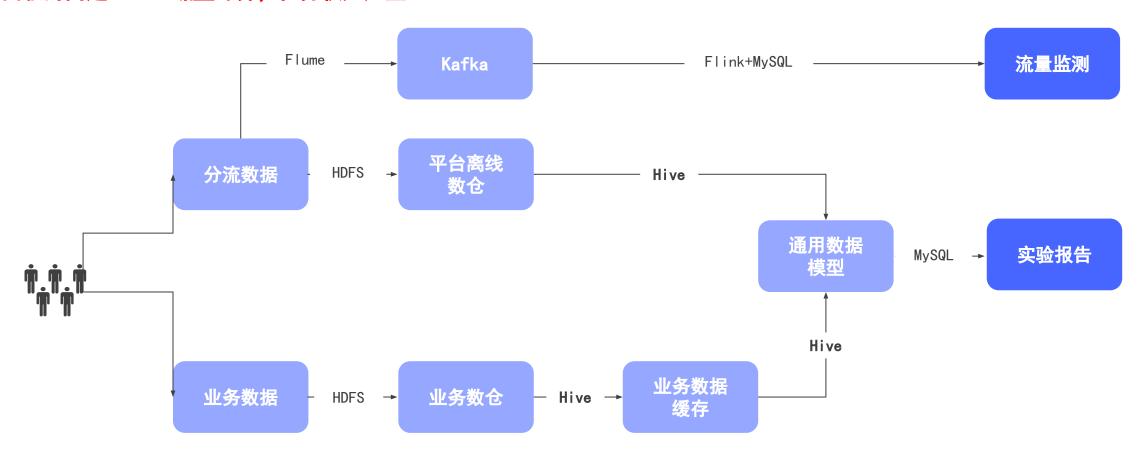
计算链路概况、技术选型





v1. 0

面临的问题: Hive磁盘计算, 任务积压严重

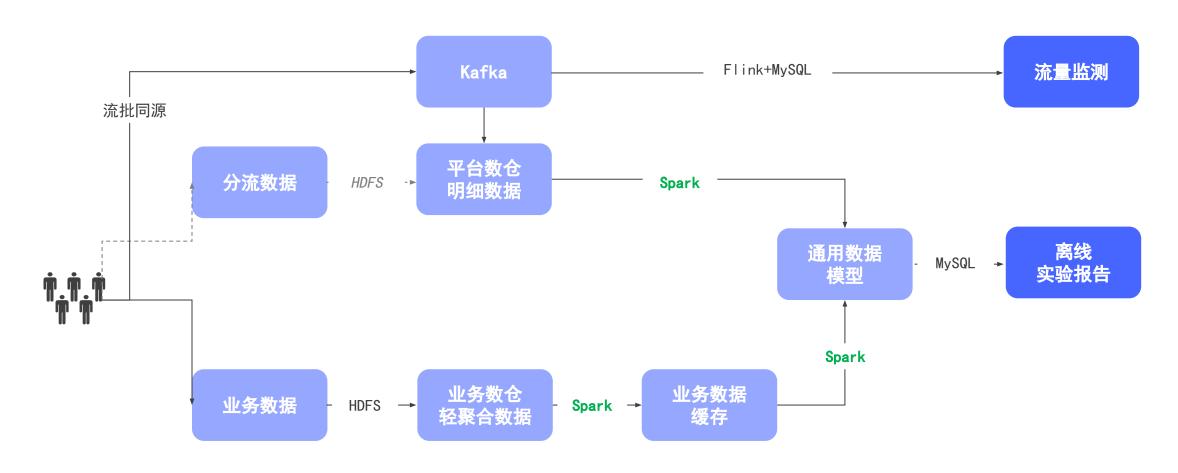




计算架构演进

v2. 0-任务执行时长整体缩短30%、计算资源节省20%,任务积压延迟情况有效缓解,队列弹性增加

面临的问题: Spark难支持多维即席分析,无法满足业务实验效果下钻归因诉求





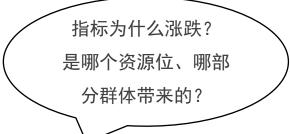


什么是实验效果下钻归因?

产出实验报告











dau提升18%

实验组	118
对照组	100

下沉 一层

实验组	资源位1	41
对照组	资源位1	38
实验组	资源位2	32
对照组	资源位2	40
实验组	资源位3	45
对照组	资源位3	22

业务上可以采取针对性措施





OLAP组件选型

诉求:支持百亿数据秒级查询、sql友好、支持灵活的维度选择、数据集构建简单







ClickHouse

- 查询响应快
- 预聚合
- 实时数据摄入
- 不适合大数据量计算
- 支持sql
- 社区活跃平稳

- 大数据量下,查询响应一般
- 支持明细查询
- 支持联邦查询、join查询
- 运维成本低
- 支持sql
- 社区活跃平稳

- 查询响应快
- 预聚合
- Sql支持完善
- 运维成本高
- 扩展差
- 社区活跃相对低

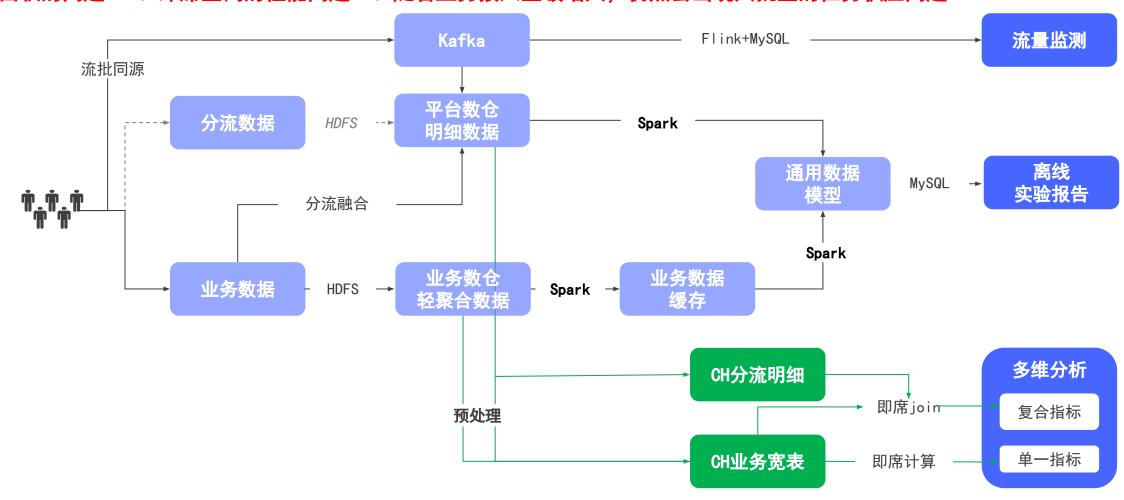
- 单表性能强悍(向量化等)
- 支持明细查询
- 支持sql
- ・ 灵活性强
- 支持主键索引、二级索引
- 社区活跃



计算架构演进

v3. 0-提供多维归因分析能力

面临的问题: 1、即席查询的性能问题 2、随着业务接入量级增大,仍然会出现大批量的任务积压问题





三、ClickHouse应用实践



性能优化实践、ClickHouse定时计算提效



性能优化实践-场景1

分流数据1亿,业务数据100亿,原查询耗时100s+,目标<10s

```
SELECT
 SELECT
   day,
                                                        day,
   实验id,
                                                         主键id,
                                                        维度1,
   方案id,
   主键id
                                                        维度2,
                                                         sum(指标) AS agg_value
 FROM
   ${分流数据}
                                                       FROM
                                                        ${业务数仓}
 WHERE
   day between '日期范围'
                                                      WHERE
   AND testappid = 'xx'
                                                         day between '日期范围'
   AND 实验id = 'XXXX'
                                                      GROUP BY
   AND 方案id IN ('71', '72', '73')
                                                         day,
                                                         主键id,
) AS t1
                                                        维度1,
                                                        维度2,...
                                                     ) AS t2
```

t1 join t2 on t1. 主键id=t2. 主键id group by day, 实验id, 方案id, 维度….





分流数据1亿,业务数据100亿,原查询耗时100s+,目标<10s

思路一、进行join优化

思路二、宽表化处理

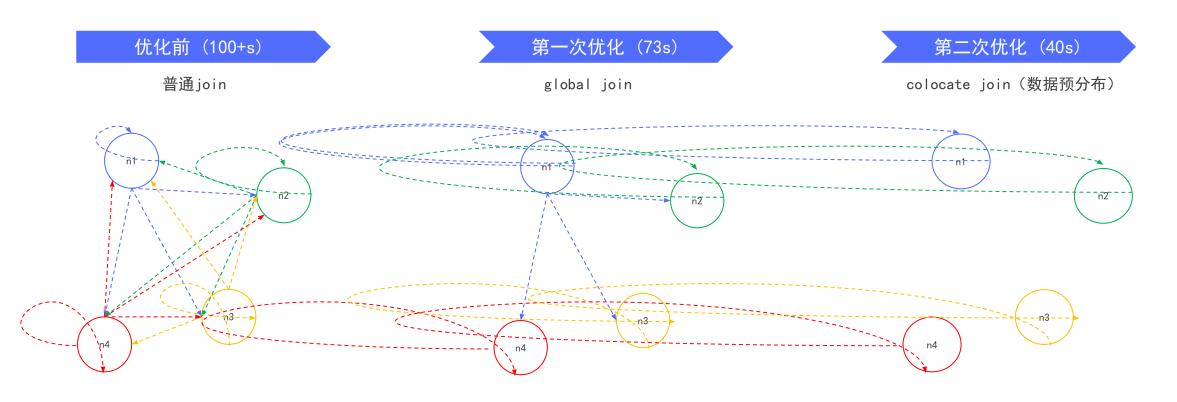
join性能可否满足即席查询需要未知

增加数据处理链路



性能优化实践-场景1

Join优化





性能优化实践-场景1

宽表化处理

分流数据

主键id	实验id	方案id
i d1	1	1001
i d1	2	2001
i d2	1	1002
i d3	2	2002

主键id	test_plan_id
i d1	1-1001, 2-2001
i d2	1-1002
i d3	2-2002

业务
轻聚
合数
据

主键id	city	cnt
id1	SZ	10
i d1	nj	13
i d2	nj	20
id3	hz	15

	主键id	test_plan_id	city	cnt
	id1	1-1001, 2-2001	sz	10
Spark2CH ——	i d1	1-1001, 2-2001	nj	13
	i d2	1-1002	nj	20
	id3	2-2002	hz	15





宽表化处理

SQL简化,查询15s

```
SELECT
day,
splitByString('-',replace(extract(test_plan_ids,',1-1001,|,
2-2001'),',','))[2] as test方案id,
count(主键id) as pv
FROM
${CH宽表}
WHERE
day between '日期范围'
AND multiMatchAny(test_plan_ids,[',1-1001,','2-2001'])
group by
day,

splitByString('-',replace(extract(test_plan_ids,',1-1001,|,2-2001')),',','))[2]
```

如何进一步优化?

性能优化实践-场景1



宽表化处理

通过explain发现主键索引失效,考虑使用二级索引(跳数索引)

```
Expression ((Projection + Before ORDER BY))
 MergingAggregated
   Union
     Aggregating
       Expression (Before GROUP BY)
         Filter (WHERE)
           ReadFromMergeTree
           Indexes:
             MinMax
               Keys:
               Condition: and(and((day in (-Inf, 19453]), (day in [19447, +Inf))), and((day in (-Inf, 19453]), (day in [19447, +Inf))))
               Granules: 87844/133899
             Partition
               Keys:
day
               Condition: and(and((day in (-Inf, 19453]), (day in [19447, +Inf))), and((day in (-Inf, 19453]), (day in [19447, +Inf))))
               Granules: 87844/87844
             PrimaryKey
               Keys:
imei
               Condition: ( not in ['', ''])
               Parts: 4/4
Granules: 87255/87844
     ReadFromRemote (Read from remote replica)
```

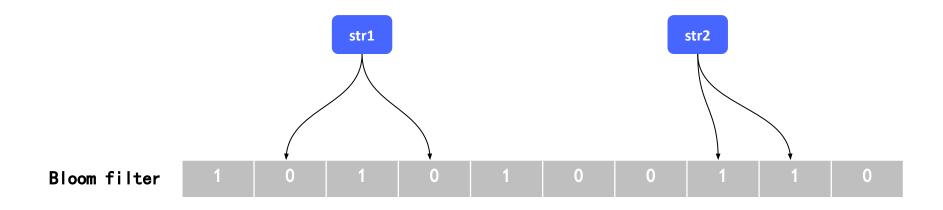




宽表化处理

跳数索引可排除不符合筛选条件的granule

INDEX idx_ids test_plan_ids TYPE ngrambf_v1(8, 256, 2, 0) GRANULARITY 20



如果hash结果不在集合中,则元素肯定不在,反之,可能在





宽表化处理

使用跳数索引并且multiMatchAny->multiSearchAny , 优化后7s

```
Expression ((Projection + Before ORDER BY))
  MergingAggregated
    Union
     Aggregating
Expression (Before GROUP BY)
Filter (WHERE)
ReadFromMergeTree
             Indexes:
               MinMax
                 Condition: and(and((day in (-Inf, 19453]), (day in [19447, +Inf))), and((day in (-Inf, 19453]), (day in [19447, +Inf))))
Parts: 4/27
                  Granules: 87844/133899
                Partition
                  Condition: and(and((day in (-Inf, 19453]), (day in [19447, +Inf))), and((day in (-Inf, 19453]), (day in [19447, +Inf))))
                  Granules: 87844/87844
               PrimaryKey
                 Keys:
imei
                 Condition: ( not in ['', ''])
                 Granules: 87255/87844
                 Description: ngrambf_v1 GRANULARITY 20
Parts: 4/4
Granules: 940/87255
      ReadFromRemote (Read from remote replica)
```



百亿数据, count distinct计算uv响应慢

优化前(120s)

```
select
sum(show_count)AS index_value,
countDistinct(主键id) AS uv
FROM
${CH表 }
WHERE
day between '日期范围'
```



第一次优化(48s)

根据主键id做分片,同时仅在本地表做聚合,分布式表汇总

```
select
    sum(index_value),
    count(*)

from
(
SELECT
    sum(show_count) AS index_value,
    主键id

FROM
    ${CH表 }
WHERE
    day between '日期范围'
    group by 主键id
Settings
distributed_group_by_no_merge = 1
)t1
```



性能优化实践-场景2

百亿数据, count distinct计算uv响应慢

第二次优化(10.8s)

select sum(show_count)AS index_value, groupBitmap(rn) AS uv FROM \${CH表 } WHERE day between '日期范围'

关键问题解决: groupBitmap入参需要为数值,但主键id为字符串

	主键id	实验id	方案id		主键id	test_plan_id						
分	id1	1	1001		id1	1-1001,2-2001						
分流数据	id1	2	2001	_	id2	1-1002						
据	id2	1	1002		id3	2-2002		37				
	id3	2	2002						主键id	主键id test_plan_id	主键id test_plan_id city	主键id test_plan_id city cnt
							J		id1	id1 1-1001,2-2001	id1 1-1001,2-2001 sz	id1 1-1001,2-2001 sz 10
11/42	主键id	city	cnt			Spar	k2C	н 🛶	H → id1	H id1 1-1001,2-2001	H → id1 1-1001,2-2001 nj	H id1 1-1001,2-2001 nj 13
业务 轻聚	id1	SZ	10			分桶排序,	抑酸	数据	id2	id2 1-1002	id2 1-1002 nj	数据 id2 1-1002 nj 20
轻聚 合数 据	id1	nj	13			── ─ 倾斜,提升						
掂	id2	nj	20									
	id3	hz	15									





CH计算定时触发,缓解Spark计算压力

yarn队列执行情况



解决问题的思路

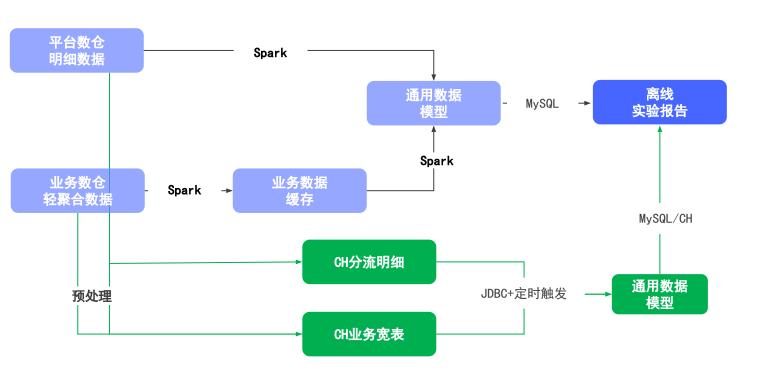
- √ 任务打散
- √ 提升计算效率



性能优化实践-场景3

vivo

CH计算定时触发,缓解Spark计算压力



优化效果

时间(分钟)	min	avg	max
Spark	14	25	40
СН	0. 03	0. 4	1



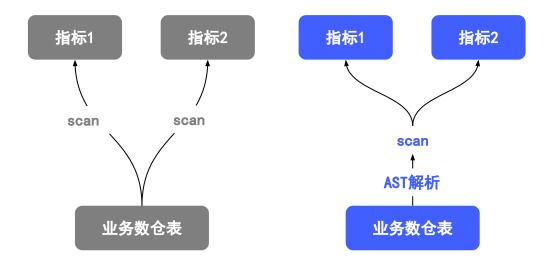


① 缩短实验效果输出周期,进一步提升决策效率





② 实验指标合并,提升计算效率





THANKS